

De modelos sintéticos a dados reais: validação empírica em redes de sensores

Sensor Crossover • Sunrise CPD

2026

Modelos sintéticos guiam a teoria • dados reais testam suas hipóteses

Ponto de partida

- Linha teórica sobre aprendizado com **poucas amostras** e **poucas *features***.
- Modelos gaussianos sintéticos com classificadores lineares / SVM.
- Submissão a periódico: **rejeitada** ✖.

O que a rejeição indicou

- A crítica *não* invalida o modelo.
- Aponta uma **fragilidade**: falta de validação em dados reais.

Mensagem

O objetivo agora é transformar uma **crítica dos revisores** em uma **agenda experimental**.

O que os revisores cobravam

Crítica	Resposta do projeto
Falta de dados reais	Usar Intel Lab (Sensor Crossover) e SensorScope (Sunrise CPD).
Modelo muito idealizado	Comparar parâmetros sintéticos com parâmetros empíricos estimados nos datasets.
Motivação em sensores pouco explorada	Trabalhar explicitamente com redes de sensores e custos de coleta/transmissão.
Posicionamento na literatura	Conectar com detecção de mudança em redes multi-sensor com restrição de recursos.

Hipótese geral do projeto

Modelo sintético

- Controle de média, variância, covariância e correlação.
- Distribuição assumida (gaussiana).
- Reprodutibilidade exata.

Dado real

- Ruído e *outliers*.
- Amostragem irregular e dados faltantes.
- Correlação empírica desconhecida.
- Distribuição não gaussiana.

Pergunta central

Os fenômenos previstos por modelos idealizados continuam aparecendo em dados reais?

Mapa da agenda experimental

SLACGS
modelo sintético
(teoria)

Sensor Crossover
Intel Lab
(dados reais)

Sunrise CPD
SensorScope
(dados reais)

- **SLACGS**: estudo teórico do trade-off *features* × amostras.
- **Sensor Crossover**: validação empírica com Intel Lab.
- **Sunrise CPD**: adaptação de detecção de ponto de mudança em rede multi-sensor sob restrição de orçamento.

*Os dois projetos reais não substituem o modelo sintético;
eles **testam e refinam** sua interpretação.*

O simulador permite controlar

- Médias das classes μ_0, μ_1 .
- Variâncias σ_i^2 .
- Covariância / correlação Σ .
- Número de *features* d .
- Número de amostras n .

Fenômeno de interesse

- Mais *features* podem **ajudar** ou **prejudicar** dependendo de n .
- Existe um ponto n^* em que usar mais *features* passa a compensar.

Conceito

Crossover: ponto n^* a partir do qual acrescentar uma *feature* reduz o erro.

No modelo sintético

- A matriz Σ é *entrada* do modelo.
- Ela é **condicionada** à estrutura de classes.

Nos dados reais começamos observando

- Covariância empírica **global**.
- Correlação empírica global.
- Versões padronizadas.

Foi necessário distinguir

- 1 Covariância **teórica** do simulador.
- 2 Covariância **empírica global** do dataset.
- 3 Correlação entre sensores reais.

A tentativa de validar com dados reais nos obrigou a entender melhor o que a covariância do modelo realmente representa.

Dataset: Intel Berkeley Research Lab

- 54 sensores de temperatura.
- $\sim 2,3$ milhões de leituras em 38 dias.

Construção do problema

- Sensores de temperatura tratados como **features**.
- Um sensor de **referência** R define as classes por separação na mediana.
- Outros sensores entram como *features* adicionais.

Pergunta

Mais sensores como *features*
sempre ajudam?

Predição teórica: existe um ponto de cruzamento n^* que depende da correlação entre os sensores.

Sensores escolhidos

- R = mote 22 (referência).
- A = mote 25 (*feature* primária).
- $B_{\text{alt}} = 31$, $B_{\text{med}} = 21$, $B_{\text{baixa}} = 48$
(correlações decrescentes).

Classificador

- SVM linear, $C = 1,0$.

Procedimento

- Variar $n \in \{2, 4, \dots, 1024\}$.
- 500 repetições Monte Carlo por (n, d) .
- Comparar erro com 1 e com 2 *features*.

Métrica de crossover

$$\Delta(n) = E_{d=1}(n) - E_{d=2}(n)$$

n^* : troca de sinal de Δ .

Cenário	$\rho(B, R)$	n^*	Tipo
Alta correlação	0,89	106	Simples
Média correlação	0,66	4 e 77	Duplo
Baixa correlação	0,38	14	Simples

Mensagem

- O **crossover** **apareceu** em dados reais.
- A **correlação** entre **sensores** desloca n^* .
- O dado real trouxe um caso de **cruzamento duplo**, comportamento mais complexo do que o previsto inicialmente no simulador.

- O experimento real reforça que “mais *features*” **não é automaticamente melhor**.
- A **qualidade** e a **relação estatística** entre sensores importam.
- Dados reais introduzem efeitos que **não estavam explícitos** no simulador (cauda das distribuições, regimes de operação, cruzamento duplo).
- Isso responde *parcialmente* à crítica dos revisores: o fenômeno teórico sobreviveu à transição para dados reais.

Mudança de problema

- De *classificação* para *detecção*.
- Tema: detecção de mudança em rede multi-sensor com **restrição de recursos**.
- Modelo teórico usa estatística **CUSUM** e política de amostragem sob orçamento.

Modelo

$$X(t) \sim \begin{cases} \mathcal{N}(\mu_0, \sigma^2) & t < \tau \\ \mathcal{N}(\mu_1, \sigma^2) & t \geq \tau \end{cases}$$

τ : instante da mudança.

$S(t)$: subconjunto de sensores escolhido dinamicamente.

Dataset: SensorScope — Grand-St-Bernard (EPFL)

- Rede de sensores ambientais sem fio em alta montanha.
- Variável usada: **radiação solar**.
- Período: setembro–outubro de 2007 (43 dias válidos).

Ground truth externo

- Nascer do sol **astronômico**.
- Evento diário com horário conhecido externamente.

Ideia

Detectar o nascer do sol como ponto de mudança **real**, com ground truth independente do detector.

Etapas

- 1 Aquisição e pré-processamento do SensorScope.
- 2 Relatório HTML do dataset.
- 3 Cálculo do *ground truth* astronômico.
- 4 Ranking global de sensores por divergência gaussiana D_i .
- 5 Detector **CUSUM** sobre razão de verossimilhança.
- 6 Política dinâmica de seleção de sensores.

Saídas

- Relatório HTML por cenário:
 - *low budget*;
 - *medium budget*;
 - *high budget*.
- Relatório de **comparação** entre os cenários.
- JSONs com métricas agregadas por dia.

Duas restrições (do artigo)

$$\sum_{i \in S(t)} C_i \leq B \quad \sum_{i \in S(t)} T_i \leq C$$

- C_i : custo de **coleta** (sensoriamento).
- T_i : custo de **transmissão**.
- $S(t)$: subconjunto escolhido a cada instante.

Custos sintéticos homogêneos: $C_i = T_i = 1$.
O primeiro sensor escolhido é **referência local**
(custo efetivo de transmissão 0); os demais são
cooperativos.

Regimes

Regime	B	C
<i>Low</i>	1	0
<i>Medium</i>	3	2
<i>High</i>	9	8

Percebemos que “budget” não podia ser apenas um conjunto fixo de sensores.

Sunrise CPD — resultados atuais

Regime	$ S(t) $ médio	No prazo	Atrasadas	Não detectadas	Atraso médio ⁺
<i>Low</i>	0,97	0/43	39/43	4/43	~ 66 min
<i>Medium</i>	2,90	0/43	41/43	2/43	~ 69 min
<i>High</i>	6,62	0/43	41/43	2/43	~ 78 min

Tolerância: ± 15 min em torno do nascer do sol astronômico.

“Atraso médio⁺” é a média de $\max(\tau - \nu, 0)$ nas detecções (estilo ADD).

Mensagem

- A **cooperação operacional** acontece: mais orçamento $\Rightarrow$ mais sensores ativos.
- Mas a detecção ficou **sistematicamente atrasada**.
- **Nenhum** regime ficou dentro da tolerância.
- Aumentar o orçamento **não melhorou a pontualidade**.

Sunrise CPD — o que deu errado e por quê

- O modelo com parâmetros gaussianos **globais** parece inadequado para o nascer do sol real.
- O nascer do sol **não é uma mudança abrupta**; é uma transição gradual.
- μ_1 global pode representar a radiação **bem depois** do nascer do sol.
- O CUSUM acaba detectando quando o aumento já está **consolidado**.
- A média dos sensores em $S(t)$ pode **diluir** sinais fortes e atrasar a estatística.

Mensagem

O problema deixou de ser apenas o *budget*; passou a ser também a **parametrização estatística** do evento real.

Parâmetros globais

- D_i global: útil como *ranking*, mas usa informação agregada do dataset.
- μ_0 global: problemático, porque cada dia tem **baseline e horário diferentes**.

Parâmetros diários

- μ_0 diário: defensável (usa só *pré-sunrise*).
- D_i diário: *quase oracle* (exige *pós-sunrise*).

Caminhos futuros

- Separar **treino e teste** de forma temporal.
- Estimar parâmetros com dados **históricos**.
- Combinar μ_0 diário com D_i global.
- **Clusterizar dias** por padrões de visibilidade e radiação; estimar parâmetros por grupo.

Projeto	Resultado	Aprendizado
SLACGS	Modelo controlado	Esclarece o papel de covariância e correlação.
Sensor Crossover	Crossover observado em dados reais	O fenômeno sintético aparece, com complexidade adicional.
Sunrise CPD	<i>Budget</i> dinâmico implementado, mas detecção atrasada	O dado real revela um <i>mismatch</i> entre modelo e fenômeno.

Mensagem

*O dado real não é apenas validação; ele é um **instrumento para descobrir hipóteses escondidas.***

Sensor Crossover

- Consolidar como **evidência empírica** do primeiro artigo.
- Estender para mais combinações de sensores e dimensões.

Sunrise CPD

- Testar baselines **diários**.
- Calibrar limiar e *drift* do CUSUM.
- Avaliar agregação ponderada e custos heterogêneos.
- Separar treino e teste no tempo.

Expansão para cenários adversariais

- Sensores comprometidos.
- Mudanças induzidas (ataques sutis).
- Cooperação sob **restrição de comunicação**.
- Conexão com detecção **robusta** em redes de sensores e com a parte covert/adversarial do artigo original.

- Já há **progresso concreto** em duas frentes empíricas.
- O **primeiro experimento** (Sensor Crossover) produziu evidência positiva: o crossover aparece em dados reais.
- O **segundo experimento** (Sunrise CPD) revelou desafios metodológicos importantes na transição teoria → dado real.
- O principal ganho foi transformar uma crítica (*“faltam dados reais”*) em uma agenda experimental com resultados verificáveis.

*“Experimentar com dados reais não apenas testa a teoria;
muitas vezes ajuda a entender melhor a própria teoria.”*